

人：这两个文档分别是我在金融科技概论课堂上分享过的计算机领域的论文，和我关心的一个金融领域的岗位。我分享的这篇计算机顶会论文是《LLMs Get Lost In Multi-Turn Conversation》，发表在 ICLR 2026，还拿到了杰出论文奖，由微软和 Salesforce 研究院团队完成，这篇论文聚焦我们日常使用大模型都会遇到的问题，现实里我们都是分多轮和 AI 沟通、一点点补充需求，但主流模型评测却只用一次性完整指令的单轮模式，两者存在巨大偏差，研究者设计了指令分片的实验方法，把完整任务拆成多条信息分轮发给 15 款主流大小模型，完成超 20 万次仿真对话测试，结果发现所有大模型在多轮对话里平均准确率直接下跌 39%，仅仅两轮对话就会出现明显性能下滑，性能变差的核心不是模型本身理解能力大幅下降，而是可靠性大幅降低，模型输出波动极大，更关键的是论文提出了“对话迷失”现象，只要 AI 前期判断出错，哪怕后面补齐全部信息，也会一直困在错误逻辑里无法修正，最后论文也给我们实际使用 AI 给出实用建议，尽量一次性完整写明全部需求，减少反复多轮修改，同时它也填补了大模型多轮对话可靠性的研究空白，指出了现有 AI 评测体系存在明显漏洞。应用在金融领域的话，针对金融智能客服，可以在对话流程中设置强制性的“需求确认节点”——在给出最终推荐之前，必须向客户确认对其需求的理解是否正确。这种设计可以在一定程度上阻断“对话迷失”的累积。我介绍的岗位是银行零售信贷客户经理，他们平时主要对接个人和小微企业，负责开发维护客户、实地核查客户资质、整理授信材料、跟进贷后还款情况还有处理各类合规报表，但平时手动核对单据特别耗时间，评估客户信用又只看重抵押物，贷后要等到客户逾期才能发现问题，写材料录系统占了大部分工作时间，还很难分辨虚假贷款材料，客户频繁询问贷款进度也很难及时回复，不过现在依靠 OCR、机器学习、智能风控预警、AI 加 RPA、知识图谱和智能客服这些金融科技手段，就能解决这些工作难题，既能帮银行降低成本、控制坏账，也能简化客户贷款流程，让缺少抵押物的小微客户也能顺利申请信贷，用数字化技术优化信贷全流程，让金融服务更高效普惠。现在需要你根据我给的资料 and 描述帮我生成一篇三千字以上的汇报，要求 1. 简要介绍论文核心内容，探讨该技术在金融领域的可行应用方式。2. 介绍该岗位日常工作内容，梳理岗位工作中会遇到的实际问题，分析金融科技如何解决上述岗位痛点。

Deepseek：大模型多轮对话“迷路”现象与金融科技赋能信贷业务革新

摘要

大语言模型已深度融入日常工作和生活，但人们在多轮对话中与 AI 交互的真实体验，与 AI 能力评测所采用的单轮完整指令模式之间存在显著偏差。ICLR 2026 杰出论文《LLMs Get Lost In Multi-Turn Conversation》通过大规模实验揭示了这一矛盾：所有主流大模型在多轮对话场景下平均性能下降 39%，且一旦“迷路”便难以自我纠正。本文首先系统介绍该论文的核心发现与研究方法，探讨其在金融领域的应用启示；随后以银行零售信贷客户经理岗位为切入点，深入分析该岗位的日常工作内容与现实痛点，并梳理金融科技各项技术如何精准解决这些痛点。本文认为，理解大模型在多轮对话中的局限性，对于金融行业理性部署 AI 系统、优化人机协作流程具有重要的实践意义。

关键词：大语言模型；多轮对话；对话迷失；金融科技；零售信贷客户经理

一、引言

2026 年，国际学习表征会议（ICLR）将杰出论文奖授予了微软研究院与 Salesforce 研究院团队的研究《LLMs Get Lost In Multi-Turn Conversation》。这篇论文之所以脱颖而出，不仅在于其实验设计的严谨性，更在于它直面了一个每一个普通用户都深有体会却鲜被学术研究正视的问题——为什么和 AI 聊得越久，它越不靠谱？

与此同时，金融行业正经历着深刻的数字化转型。大模型、大数据、人工智能等前沿技术正在重塑金融服务的每一个环节。银行零售信贷客户经理作为金融服务的一线触角，其日常工作既承载着银行与客户之间的信任桥梁功能，也承受着传统作业模式带来的效率瓶颈与合规压力。金融科技能否真正解决这些痛点？大模型在多轮对话中的固有限制又给金融 AI 应用带来了哪些警示？本文试图在技术前沿与业务实践之间建立对话，探讨二者的交汇点与启示。

二、《LLMs Get Lost In Multi-Turn Conversation》论文核心解读

2.1 研究背景：一个被忽视的矛盾

论文的出发点是一个简单却深刻的观察：我们日常使用 AI 的方式与 AI 能力的主流评测方式“根本不是一回事”。

在日常场景中，用户往往通过多轮对话逐步向 AI 传达需求——先给一个大致方向，再补充细节，再修正偏差。然而，主流的大模型评测体系却采用“单轮、完整指令”的模式：一次性提供严密的任务描述，要求 AI 一次性完成，做完即打分，没有追问和修正的机会。这种评测方式与真实使用场景之间存在着巨大的偏差。

论文作者团队来自微软研究院和 Salesforce 研究院，包括 Philippe Laban、Hiroaki Hayashi、Yingbo Zhou 和 Jennifer Neville。他们设计了一套可扩展的方法来评估大模型的多轮对话能力，试图回答三个核心问题：当用户在多轮对话中逐步把需求说清楚时，AI 的表现与一次性完整告知相比到底差多少？如果有差距，是“能力不行了”还是“变得不可靠了”？如果是后者，有没有规律可循？

2.2 研究方法：指令分片法

论文的核心实验方法被命名为“指令分片法”（Sharding），其设计极为简洁却直击要害。

第一步——提取指令：从现有高质量测试集中选取一条完整的单轮指令，例如一道数学应用题或一段编程需求。

第二步——指令分片：将这条完整指令切分成多个逻辑上独立的信息碎片（shards）。每个碎片包含任务的一部分信息，但单独看并不足以完成整个任务。

第三步——分轮输入：在模拟的多轮对话中，每轮只向 AI 揭示一个碎片信息，要求模型基于当前获得的信息做出回答。关键控制变量在于：总信息量与单轮场景完全一致，唯一区别是“一次性输入”还是“分批次输入”。

第四步——结果对比：将多轮对话下 AI 的最终回答与直接输入完整指令的单轮回答进行准确率对比。

这种实验设计的精妙之处在于，它严格排除了“信息量不同”这一干扰因素——如果多轮场景下性能下降，原因只能是交互模式本身，而非信息缺失。

2.3 实验规模与覆盖范围

论文的实验规模令人印象深刻：

模拟对话总次数：超过 20 万次，构成了工业级的大规模对话实验数据支撑。

测试模型数量：15 个主流模型，涵盖开源小模型与闭源大模型，包括 GPT-4.1、Claude 3.7 Sonnet、Gemini 2.5 Pro、DeepSeek-R1、Llama 4-Scout 等。

任务类型：6 种核心任务场景，包括代码生成、SQL 查询、函数调用、数学推理、数据转文本生成、多文档摘要。

信息碎片梯度：从 1 个碎片到多个碎片，完整验证模型的长程依赖能力。

2.4 三大核心发现

发现一：所有主流模型全部大幅下降

实验结果显示，所有测试模型在多轮对话中的平均性能下降了 39%。具体而言，GPT-4.1 从 91.7%降至 70.7%，Claude 3.7 Sonnet 从 85.4%降至 70.0%，Gemini 2.5 Pro 从 90.2%降至 64.3%。更令人警惕的是，性能下降的拐点出现得极早——仅需两轮对话就足以引发明显的性能衰减。更大、更先进的模型并未展现出对抗这种性能退化的优势。

发现二：罪魁祸首是“不可靠”，不是“能力差”

论文将性能下降分解为两个维度：能力（aptitude）和可靠性（reliability）。分析表明：

能力损失：模型核心理解能力仅下降了约 16%，表现出轻微的“变笨”迹象，这仅能解释约 15%的整体性能下降。

可靠性崩塌：模型行为的一致性急剧下降，不可靠性增幅高达 112%。

这意味着，多轮对话并没有让模型变笨太多，而是让它变得“时对时错”、极不稳定。在真实业务场景中，这种不可预测性比平均性能下降更加危险——同一个 AI 处理同一个任务，可能这次完美完成，下次却彻底失败。

发现三：“对话迷失”——一旦走错，再也回不来

论文提出了“对话迷失”（Lost in Conversation）现象。其机制如下：在第一轮对话中，AI 基于有限信息过早做出判断，锁定了某个错误方向；在后续轮次中，即便用户补全了所有信息，AI 仍然沿着最初的错误路径思考，无法自我纠正。论文将其描述为：“当 LLMs 在对话中走错方向时，它们会迷路，并且无法恢复。”

这一发现解释了为什么日常使用中，一旦 AI 在某轮对话中理解偏了，后续再怎么解释和纠正都难以让它回到正轨——它已经被“锁死”在错误的初始假设上了。

2.5 论文的学术贡献与现实意义

ICLR 2026 评奖委员会对这篇论文的评价是：“该工作展示了出色的实验设计和方法论，其发现在一个更贴近真实使用场景的重要设定中具有新鲜性和趣味性”。论文填补了大模型多轮对话可靠性研究的空白，指出现有 AI 评测体系的明显漏洞。

对于普通用户，论文给出了非常实用的建议：尽量一次性把完整需求写清楚，提供充分的上下文，不要给 AI“猜”的机会。对于企业级 AI 应用，这意味着在设计人机交互流程时，需要充分考虑大模型在多轮对话中的固有限制。

三、大模型多轮对话局限性的金融应用启示

3.1 金融行业 AI 应用的现状

金融行业正加速拥抱大模型技术。以中国光大银行为例，该行已推动大模型技术在客户经理赋能、合规运营、远程坐席等场景落地。其授信尽调智能报告功能基于大模型和大数据技术，帮助客户经理按章节自动生成授信尽调报告。传统流程下，撰写一份百页授信尽调报告平均需要 7 天，如今借助大模型技术，3 至 5 分钟即可完成。该功能已推广至 39 家一级分行，服务近 2000 名客户经理，撰写超过 5000 份尽调报告。

然而，大模型在金融行业的落地并非坦途。大模型的“幻觉”问题、准确度不及预期、价值观偏差等局限依然突出。论文揭示的多轮对话“迷路”现象，为金融 AI 应用提供了重要的警示——尤其是在那些依赖多轮交互的金融场景中。

3.2 金融智能客服中的“对话迷失”风险

金融智能客服是大模型多轮对话应用最为典型的场景之一。客户在咨询贷款产品、查询进度、了解政策时，往往需要通过多轮对话逐步明确需求。根据论文的发现，这种交互模式恰恰是大模型最容易“迷路”的场景。

更值得警惕的是“对话迷失”的累积效应。如果智能客服在第一轮对话中误解了客户意图（例如将“我想了解小微企业贷款”误解为“我想查询个人消费贷”），后续即便客户反复澄清，模型也可能被锁死在错误的轨道上。金融服务的容错率极低——一个错误的贷款推荐、一条不准确的利率解读，都可能带来严重的合规风险与客户信任损失。

3.3 针对性设计建议：阻断“对话迷失”的累积

基于论文的发现，金融行业在部署大模型驱动的对话系统时，可以考虑以下设计原则：

第一，设置“需求确认节点”。在对话流程中插入强制性的确认环节——在给出最终推荐或决策之前，必须向客户复述并确认对其需求的理解。这相当于在“迷失”发生之前设置一道检查关卡。

第二，优先采用“一次性完整输入”模式。在可能的情况下，引导客户一次性提供完整需求（例如通过结构化表单），而非依赖多轮对话逐步澄清。论文证实，当信息以单条完整消息而非多轮分片的方式呈现时，性能可恢复到单轮基准的 95%。

第三，设计“重置”机制。当检测到对话出现歧义或潜在误解时，允许系统“重置”对话状态，重新开始而非试图在错误方向上修补。后续研究也表明，通过特定的训练框架可以帮助模型在多轮对话中找回单轮水准。

第四，关键决策保留人工审核。对于涉及信贷审批、风险评估等重大决策的场景，大模型的输出应作为辅助参考而非最终依据，保留人类专家的审核环节。

四、银行零售信贷客户经理岗位分析

4.1 岗位职责概览

银行零售信贷客户经理是银行与个人及小微企业客户之间的桥梁。其日常工作主要包括以下五个维度：

客户开发与维护：挖掘小微企业与个人客户的信贷需求，建立并维护长期信任关系，持续拓展业务版图。

贷前尽职调查：实地考察客户经营场所，核验各类资料，交叉验证客户经营状况与还款能力，精准评估信贷风险。

资料整理与上报：按照银行规范撰写授信报告，准确录入业务系统，配合风控部门完成审批流程。

全周期贷后管理：定期跟踪客户经营动态，监控资金流向与还款记录，确保信贷资产安全，及时发现潜在风险。

合规把控与行政支持：严格遵守银行信贷政策与监管要求，完成大量文件归档、报表统计等基础行政工作，保障业务合规运营。

4.2 岗位面临的六大痛点

零售信贷客户经理在日常工作中面临诸多挑战：

痛点一：信息核验低效。客户经理需要手动核对客户的银行流水单、合同、税务证明等大量纸质或电子材料，不仅耗时费力，还极易出现人工疏漏和录入错误。

痛点二：事务性工作繁重。大量工作时间被撰写授信报告、系统录入、档案整理等事务性工作占据，真正用于挖掘客户、深度服务客户的时间极为有限。

痛点三：信用评估片面。传统信贷评审过度依赖房产抵押和征信记录，导致大量经营状况良好但缺乏合格抵押物的优质小微企业被拒之门外，既损失了银行业务机会，也违背了普惠金融的初衷。

痛点四：欺诈风险难防范。面对精心伪造的合同、流水等申请材料，传统人工审核手段识别能力有限，极易造成坏账损失。

痛点五：贷后管理被动。贷后管理主要依靠定期电话回访或上门拜访，缺乏实时监控手段，往往在客户已经逾期或经营严重恶化之后才发现问题，丧失了风险处置的黄金窗口。

痛点六：客户服务效率低。客户频繁来电或到访咨询贷款进度、政策变化等问题，客户

经理需要人工逐一查询反馈，流程繁琐且响应速度慢，客户体验不佳。

4.3 金融科技如何解决痛点

金融科技通过一系列前沿技术，正在系统性地破解上述痛点：

OCR 图像识别+大数据自动核验：针对信息核验低效的问题，OCR 技术可自动读取和识别各类单据中的关键信息，结合大数据交叉验证，效率提升 80%以上，大幅减少人为录入错误。

机器学习信用评分模型：针对信用评估片面的问题，机器学习模型可整合客户的多维行为数据与交易数据，构建全面立体的信用评估体系，不再单纯依赖抵押物，让更多优质小微客户获得信贷服务。

智能风险预警平台：针对贷后管理被动的问题，智能风控平台可实时监控资金流向与各类风险信号，变“事后补救”为“事前预警”，有效降低坏账率。

生成式 AI+RPA 自动化：针对事务性工作繁重的问题，生成式 AI 可自动撰写分析报告和授信材料，RPA 机器人可自动完成系统录入与数据填报，将客户经理从繁琐的事务中解放出来，聚焦核心业务。正如光大银行的实践所示，大模型技术已将授信尽调报告撰写时间从 7 天压缩至 3 至 5 分钟。

知识图谱反欺诈系统：针对欺诈风险难防的问题，知识图谱技术可精准识别客户之间的关联关系与隐性借贷网络，快速发现跨平台骗贷团伙和“老赖”。

智能客服+进度可视化：针对客户服务低效的问题，智能客服可 7×24 小时响应客户咨询，进度可视化系统让客户随时查询业务进展，大幅减少人工咨询量，提升服务体验。目前，基于大模型的新一代智能客服机器人已广泛应用于银行、保险、证券等金融机构的在线客服与业务办理环节。

五、总结与展望

《LLMs Get Lost In Multi-Turn Conversation》这篇 ICLR 2026 杰出论文，以简洁的实验设计和令人警醒的结论，揭示了大语言模型在多轮对话中的系统性缺陷：39%的平均性能下降、112%的可靠性崩塌、以及一旦“迷路”便无法恢复的“对话迷失”现象。这些发现不仅对 AI 研究者具有重要的学术价值，更对金融等高风险行业的 AI 部署具有深刻的实践启示。

对于银行零售信贷客户经理这一岗位而言，金融科技正在从信息核验、信用评估、贷后管理、事务处理、反欺诈、客户服务六个维度全面赋能。OCR、机器学习、知识图谱、生成式 AI、RPA、智能客服等技术不再是实验室里的概念，而是切实改变着客户经理每一天的工作方式。正如业界所言：“大模型不是实验室玩具，而是解决业务痛点的工具。”

然而，技术赋能不等于技术迷信。大模型在多轮对话中的固有限制提醒我们：在部署金融 AI 系统时，需要理性评估技术的边界，设计合理的人机协作流程，在关键环节保留人类的判断与审核。唯有如此，才能真正实现“让金融服务变得更高效、更普惠、更智能”

的愿景。

参考文献

[1] Laban, P., Hayashi, H., Zhou, Y., & Neville, J. LLMs Get Lost in Multi-Turn Conversation. ICLR 2026 (Outstanding Paper Award).

[2] ICLR 2026 Outstanding Paper Committee. Announcing the ICLR 2026 Outstanding Papers. ICLR Blog, 2026.

[3] Beam.ai. LLMs Lose 39% Accuracy in Multi-Turn Conversations | ICLR 2026's Outstanding Paper Explains Why. 2026.

[4] Salesforce AI Research. Salesforce at ICLR 2026.

[5] 新华财经. 自动化生成授信尽调报告，人机协同重构银行智慧内核——专访中国光大银行副行长杨兵兵. 2025.

[6] 证券时报. 见证金融 AI“换芯”：从“外挂”进化为“原生”. 2026.

[7] 金融壹账通. 基于大模型的新一代智能客服机器人已服务数十家金融机构. 2026.

人：# 大模型多轮对话“迷路”现象与金融科技赋能信贷业务革新

摘要

大语言模型已深度融入日常工作和生活，但人们在多轮对话中与 AI 交互的真实体验，与 AI 能力评测所采用的单轮完整指令模式……AI 系统时，需要理性评估技术的边界，设计合理的人机协作流程，在关键环节保留人类的判断与审核。唯有如此，才能真正实现“让金融服务变得更高效、更普惠、更智能”的愿景。

请你用自然流畅的中文润色以上文本，避免机械的连接

Deepseek: 大模型多轮对话“迷路”现象与金融科技赋能信贷业务革新

摘要

大语言模型已深度嵌入日常工作和生活，然而人们在多轮对话中与 AI 交互的真实体验，同 AI 能力评测所采用的单轮完整指令模式之间存在着显著偏差。ICLR 2026 杰出论文《LLMs Get Lost In Multi-Turn Conversation》通过大规模实验揭示了这一矛盾：所有主流大模型在多轮对话场景下平均性能下降 39%，且一旦“迷路”便难以自行纠正。本文首先系统梳理该论文的核心发现与研究方法，并探讨其对金融领域应用的相关启示；随后以银行零售信贷客户经理岗位为切入点，分析该岗位的日常工作内容与现实痛点，梳理金融科技各项技术如何针对性地解决这些问题。本文认为，理解大模型在多轮对话中的固有局限，对于金融行业理性部署 AI 系统、优化人机协作流程具有切实的实践意义。

关键词：大语言模型；多轮对话；对话迷失；金融科技；零售信贷客户经理

一、引言

2026 年，国际学习表征会议（ICLR）将杰出论文奖授予了微软研究院与 Salesforce 研究院团队的研究《LLMs Get Lost In Multi-Turn Conversation》。这篇论文之所以能在众多投稿中脱颖而出，不仅在于其实验设计的严谨扎实，更在于它回应了一个几乎每个普通

用户都曾亲身经历、却鲜被学术研究正视的问题——为什么跟 AI 聊得越久，它反而越不靠谱？

与此同时，金融行业正经历着深刻的数字化转型。大模型、大数据、人工智能等前沿技术正在重塑金融服务的各个环节。银行零售信贷客户经理身处金融服务的第一线，他们的日常工作既承载着银行与客户之间的信任桥梁功能，也承受着传统作业模式带来的效率瓶颈与合规压力。金融科技能否有效解决这些痛点？大模型在多轮对话中的固有限制又给金融 AI 应用带来了哪些值得警惕的信号？本文希望在技术前沿与业务实践之间搭建一个对话的通道，探寻二者的交汇点与相互启发。

二、《LLMs Get Lost In Multi-Turn Conversation》论文核心解读

2.1 研究背景：一个被忽视的矛盾

论文的出发点建立在一个简单却深刻的观察之上：我们日常使用 AI 的方式，与 AI 能力的主流评测方式“根本不是一回事”。

在真实使用场景中，用户往往通过多轮对话逐步向 AI 传递需求——先给一个大致方向，再补充细节，再修正偏差。这是一个渐进式的、符合人类沟通习惯的自然过程。然而主流的大模型评测体系走的是另一条路：一次性提供严密完整、包含所有必要信息的任务描述，要求 AI 一次性给出最终答案，答完即打分，没有追问、没有修正、没有后续交互的机会。评测模式与真实使用场景之间，存在着一条巨大的鸿沟。

论文的作者团队来自微软研究院和 Salesforce 研究院，四位研究者分别是 Philippe Laban、Hiroaki Hayashi、Yingbo Zhou 和 Jennifer Neville。他们设计了一套可扩展的评估框架，试图回答三个核心问题：当用户在多轮对话中分步把需求说清楚时，AI 的表现与一次性完整告知相比，到底差了多少？如果存在差距，原因是“能力不行了”，还是“变得不可靠了”？如果是后者，这种不可靠性有没有规律可循？

2.2 研究方法：指令分片法

论文的核心实验方法被命名为“指令分片法”，其设计思路极为简洁，却准确地击中了问题的要害。

第一步是提取指令。研究者从现有的高质量测试集中选取一条完整的单轮指令，可以是一道数学应用题，也可以是一段编程需求。第二步是指令分片，将这条完整指令切分成多个逻辑上独立的信息碎片，每个碎片包含任务的一部分信息，单独拿出来不足以支撑 AI 完成整个任务。第三步是分轮输入，在模拟的多轮对话中，每一轮只向 AI 揭示一个碎片，同时要求模型基于当前已获得的所有信息做出回答。这里最关键的变量是：总信息量与单轮场景完全一致，唯一的区别在于信息是“一次性到位”还是“分批送达”。第四步是结果对比，将多轮对话下 AI 的最终答案与一次性输入完整指令的单轮答案进行准确率比较。

这套实验设计的精妙之处在于，它严格排除了“信息量不同”这一潜在干扰因素——如果多轮场景下出现了性能下降，原因只能是交互模式本身造成的，而不是信息缺失所致。

2.3 实验规模与覆盖范围

论文的实验规模相当可观。模拟对话总次数超过 20 万次，构成了工业级的实验数据基础。测试模型数量达到 15 个，涵盖了开源小模型与闭源大模型两个阵营，包括 GPT-4.1、Claude 3.7 Sonnet、Gemini 2.5 Pro、DeepSeek-R1、Llama 4-Scout 等市场主流产品。任务类型覆盖了六个核心场景，包括代码生成、SQL 查询、函数调用、数学推理、数据转文本生成和多文档摘要。信息碎片的数量也设置了从 1 个到多个的完整梯度，用以验证模型的长程依赖能力如何随着对话轮次的增加而变化。

2.4 三大核心发现

实验得出的结论令人警醒。第一个发现是，所有参与测试的主流模型在多轮对话中的平均性能均出现了大幅下降，降幅达到 39%。以具体数据来看，GPT-4.1 从 91.7% 降至 70.7%，Claude 3.7 Sonnet 从 85.4% 降至 70.0%，Gemini 2.5 Pro 从 90.2% 降至 64.3%。更值得关注的是，性能滑坡的拐点来得极早——仅仅两轮对话就足以触发明显的性能衰减。模型规模越大、能力越强，也未能展现出抵御这种衰退的优势。

第二个发现指向了性能下降的内在机理。论文将下降原因拆解为两个维度：能力（aptitude）和可靠性（reliability）。分析结果显示，模型核心理解能力的损失大约只有 16%，表现出的“变笨”程度其实相当轻微，这部分仅能解释约 15% 的整体性能滑坡。真正的大头在于可靠性的崩塌——模型行为的一致性急剧下滑，不可靠性的增幅高达 112%。换言之，多轮对话并没有让模型变笨多少，而是让它变得“时对时错”、极不稳定。在真实业务场景中，这种不可预测性比平均性能下降更加棘手，因为使用者无法判断哪一次该相信它的输出、哪一次该保持警惕。

第三个发现被论文命名为“对话迷失”。其机制大致是这样的：在第一轮对话中，AI 基于有限的信息过早地做出了判断，锁定了某一个方向；如果这个方向本身是错的，问题就随之而来。在后续轮次中，即使用户补全了所有信息，模型仍然沿着最初那条错误的路径一路走到黑，无法自行掉头。论文用一句话概括了这个现象：“当 LLMs 在对话中走错方向时，它们会迷路，并且无法恢复。”这也解释了为什么日常使用中，一旦 AI 在某轮对话中理解偏了，后续再怎么解释、再怎么纠正，都很难把它拉回正轨——它已经被锁死在最初的错误假设上了。

2.5 论文的学术贡献与现实意义

ICLR 2026 的评奖委员会对这篇论文的评价是：该工作展示了出色的实验设计和方法论，其发现在一个更贴近真实使用场景的重要设定中具有新鲜性和趣味性。这篇论文填补了大模型多轮对话可靠性研究的一块空白，同时也指出了现有 AI 评测体系存在的明显漏洞。

对于普通用户，论文给出了一个很务实的建议：尽可能一次性把完整需求写清楚，提供充分的上下文，不要给 AI 留太多“猜”的空间。对于企业级 AI 应用，这个结论意味着在设计人机交互流程时，必须把大模型在多轮对话中的固有限制作为一个重要的考量因素。

三、大模型多轮对话局限性的金融应用启示

3.1 金融行业 AI 应用的现状

金融行业正在加快拥抱大模型技术的步伐。以中国光大银行为例，该行已推动大模型技术在客户经理赋能、合规运营、远程坐席等多个场景落地。其授信尽调智能报告功能基

于大模型和大数据技术，帮助客户经理按章节自动生成授信尽调报告。在传统工作流程下，撰写一份上百页的授信尽调报告平均需要 7 天时间，而借助大模型技术，3 到 5 分钟即可完成初稿。该功能目前已推广至 39 家一级分行，服务近 2000 名客户经理，累计撰写超过 5000 份尽调报告。

然而大模型在金融行业的落地并非一帆风顺。“幻觉”问题、输出准确度不及预期、价值观对齐偏差等局限依然突出。论文所揭示的多轮对话“迷路”现象，为金融 AI 应用提供了一个重要的警示——尤其是在那些天然依赖多轮交互的金融场景中，这个问题尤其值得关注。

3.2 金融智能客服中的“对话迷失”风险

金融智能客服是大模型多轮对话应用最为典型的前沿阵地。客户在咨询贷款产品、查询办理进度、了解政策条款时，往往需要通过多轮对话逐步明确自己的需求。而根据论文的发现，这种交互模式恰恰是大模型最容易“迷路”的雷区。

更值得警惕的是“对话迷失”具有累积效应。如果智能客服在第一轮对话中就把客户的意图理解偏了——比如将“我想了解小微企业贷款”误判为“我想查询个人消费贷”——那么即便客户在后续对话中反复澄清，模型也可能已经被锁死在错误的轨道上。金融服务与普通问答不同，它的容错率极低。一个错误的贷款推荐、一条不准确的利率解读，都有可能演变成合规风险，同时侵蚀客户对机构的信任。

3.3 针对性设计建议：阻断“对话迷失”的累积

基于论文的研究发现，金融行业在部署大模型驱动的对话系统时，有几点设计原则值得认真考虑。

第一，设置需求确认节点。在对话流程中插入一个强制性的确认环节——在给出最终推荐或决策之前，先向客户复述一遍对其需求的理解，确认无误后再进入下一步。这个环节相当于在“迷失”发生之前设置了一道检查关卡。第二，在可能的情况下优先采用“一次性完整输入”模式。通过结构化表单等方式引导客户一次性把需求说清楚，而不是依赖多轮对话逐步澄清。论文的实验数据表明，当信息以单条完整消息而非多轮分片的方式呈现时，性能可以恢复到单轮基准的 95%。第三，设计重置机制。当系统检测到对话中出现了明显的歧义或潜在误解时，允许直接重置对话状态、重新开始，而不是在错误的路径上不断修补。第四，关键决策保留人工审核。对于涉及信贷审批、风险评估等重大决策的场景，大模型的输出应当定位为辅助参考而非最终依据，人类专家的审核环节不能缺位。

四、银行零售信贷客户经理岗位分析

4.1 岗位职责概览

银行零售信贷客户经理是银行与个人及小微企业客户之间的桥梁。这个岗位的日常工作大致可以归纳为五个方面。

客户开发与维护是第一位的。客户经理需要主动挖掘小微企业与个人客户的信贷需求，通过持续的沟通与服务建立长期信任关系，不断拓展业务版图。贷前尽职调查紧随其后，这是一项极为考验专业素养的工作，客户经理要实地走访客户的经营场所，核验各类证

明材料，通过多渠道的信息交叉验证来判断客户的真实经营状况与还款能力。资料整理与上报则是将前面的调查成果转化为规范的授信报告，准确录入业务系统，提交给风控部门走审批流程。贷款发放之后，全周期贷后管理便开始了，客户经理需要定期跟踪客户的经营动态，监控资金流向与还款记录，确保信贷资产在整个存续期内都在安全范围内。此外还有合规把控与行政支持，客户经理必须严格遵守银行的信贷政策和监管要求，同时完成大量文件归档、报表统计等基础行政工作，保障业务合规运营。

4.2 岗位面临的六大痛点

这个岗位虽然重要，但在实际工作中面临着不少棘手的问题。

第一个痛点是信息核验低效。客户经理每天要面对大量纸质或电子版的银行流水、合同文件、税务证明、经营执照，需要逐项逐条地人工核对。这个过程不仅耗时，而且人总会疲惫、总会看花眼，疏漏和录入错误难以完全避免。第二个痛点是事务性工作繁重。撰写授信报告、录入业务系统、整理归档文件——这些事务性的工作占据了客户经理大半的工作时间，真正用来走出去拜访客户、深入了解客户需求、拓展新业务的时间反而被挤占得所剩无几。第三个痛点是信用评估手段单一。传统的信贷评审过度依赖房产、车辆等有形抵押物和央行征信记录，大量经营状况良好、现金流稳定但缺少合格抵押物的小微企业主和个体户被挡在了银行大门之外。这对银行来说是错失了优质客户资源，对整个社会而言也不利于普惠金融的推进。第四个痛点是欺诈风险难以防范。现在有些骗贷团伙手法极其专业，伪造的合同、流水、税票足以以假乱真，光靠客户经理肉眼识别和主观经验判断，很难发现问题。一旦中招，坏账就实实在在地产生了。第五个痛点是贷后管理非常被动。贷后管理主要依靠客户经理定期打电话回访或者上门实地查看，缺乏实时、自动化的监控手段。很多情况下，要等到客户已经出现逾期，银行这边才后知后觉，风险处置的最佳时机早已错过。第六个痛点是客户服务效率不高。客户想查询贷款审批进度、想了解最新的利率政策，最直接的方式就是打电话找自己的客户经理。客户经理就得放下手头的事情去系统里查询，查到之后再回电话。这个来回折腾的过程效率很低，客户体验也不好，客户经理也被频繁的咨询电话切碎了工作时间。

4.3 金融科技如何解决痛点

针对这六个痛点，金融科技正好提供了一整套有针对性解决方案。

在信息核验环节，OCR 图像识别技术加上大数据平台可以发挥很大作用。客户经理只需将收到的材料扫描或拍照上传，系统自动读取和识别关键字段，同时连接工商、税务、征信等外部数据源进行自动交叉验证。效率提升超过 80%，而且机器不会疲劳、不会看走眼，识别准确率比人工肉眼要高出不少。在信用评估方面，基于机器学习的信用评分模型可以整合大量多维数据——不仅包括传统的征信记录，还有客户的经营流水、交易行为、上下游关系、甚至社交网络信息等——构建出一个立体、动态的信用画像。不再唯抵押物论，很多经营状况良好但缺乏抵押物的小微客户因此获得了信贷支持的可能。在反欺诈领域，知识图谱反欺诈系统是一个极为有力的武器。它把客户、关联人、企业、账户、设备等各类实体之间的关系绘制成一张巨大的网络，通过图算法自动识别异常的资金循环、隐蔽的关联担保、跨平台的骗贷团伙，比人工审核敏锐得多、精准得多。在减轻事务性工作方面，生成式 AI 加上 RPA 机器人流程自动化正在改变客户经理的工作方式。生成式 AI 可以根据录入的数据自动撰写授信分析报告，RPA 机器人可以自动把数据填入各个业务系统。光大银行的案例就是一个很好的注脚——一份原本要写 7 天的

授信报告，如今几分钟就能生成初稿，效率的提升是数量级的。在贷后管理方面，智能风险预警平台可以 7×24 小时实时监控贷款客户的资金流向、经营动态、征信变化等各类风险信号。一旦出现异常，系统自动报警，客户经理收到提示后可以提前介入，而不是等逾期发生了再被动应对。在客户服务方面，智能客服加上进度可视化系统，让客户可以随时随地在线查询自己的贷款进度，常见问题由智能客服自动应答，只有真正复杂的疑难问题才需要转接人工。客户的体验大幅改善，客户经理被琐碎咨询频繁打扰的困扰也大大减轻了。

五、总结与展望

《LLMs Get Lost In Multi-Turn Conversation》这篇 ICLR 2026 杰出论文，用简洁的实验设计和令人警醒的结论，揭示了大语言模型在多轮对话中的系统性缺陷：39%的平均性能滑坡、112%的可靠性崩塌、以及一旦“迷路”便无法自行恢复的“对话迷失”现象。这些发现不仅对 AI 研究者具有重要的学术价值，对于金融等高风险行业的 AI 部署同样具有深刻的实践启示。

在银行零售信贷客户经理这个岗位上，金融科技正在从信息核验、信用评估、贷后管理、事务处理、反欺诈、客户服务六个维度全面展开赋能。OCR、机器学习、知识图谱、生成式 AI、RPA、智能客服等技术不再是实验室里的概念，而是切切实实地改变着客户经理每一天的工作方式。正如业界所说，大模型不是实验室里的玩具，而是解决真实业务痛点的工具。

不过，技术赋能不等于技术迷信。大模型在多轮对话中暴露出的固有限制提醒我们：在部署金融 AI 系统时，既要看到技术带来的效率红利，也要理性评估它的能力边界，设计合理的人机协作流程，在关键环节保留人类的判断与审核。唯有如此，才能让金融服务朝着更高效、更普惠、更智能的方向稳步前行，而不是为了技术而技术。

放所有图片文件太大传不上去 a

