

一、计算机论文分享

我今天分享的第一项内容，是一篇发表在 ICLR 2026 上的计算机学科学术论文，题目翻译过来叫做《大模型在多轮对话中为何会“迷路”》。ICLR 是机器学习领域公认的顶级会议之一，这篇论文拿到了当年的杰出论文奖，全球每年只有两篇论文能获得这个荣誉，分量很重。作者团队来自微软研究院和 Salesforce 研究院，都是国际上做人工智能研究非常顶尖的工业界机构。

这篇论文讨论的问题，其实我们每个人都亲身经历过。你在使用像 ChatGPT、Claude 或者国内的各种大模型产品时，有没有发现一个现象：刚开始聊的那几轮，AI 回答得挺好，挺靠谱，但是随着对话轮次增加，你继续补充信息、提出修改要求，它反而越来越不在状态，甚至开始胡说八道。这就是论文标题里所说的“迷路”。

论文作者敏锐地指出了长期被忽视的矛盾。我们日常使用 AI 的方式，绝大多数情况下是多轮对话式的。比如我想让 AI 帮我写一份材料，我的习惯通常是先给一个大方向，说“帮我写个东西”，然后第二轮补充“是关于金融科技方面的”，第三轮再说“要包含具体的案例分析，不要空话套话”，第四轮可能还会说“你上一版逻辑不太对，重新调整一下”。这是非常自然的、符合人类沟通习惯的方式。但是，主流的大模型能力评测，采用的却是完全相反的模式。评测的时候，是一次性给 AI 一段非常完整、非常严密的指令，包含了所有必要的信息，然后让 AI 一次性生成最终答案，评测人员直接打分，任务就结束了，没有任何追问和修正的机会。这就产生了一个巨大的矛盾：我们在用多轮对话的方式跟 AI 协作，但评测却在用单轮对话的方式给 AI 打分。两者之间是否存在偏差？偏差有多大？这就是论文要回答的核心问题。

为了回答这个问题，研究者设计了一套非常巧妙的实验方法，叫做“指令分片法”。这个方法的核心逻辑很简单：把同一条完整指令，分别用两种方式交给 AI，一种是完整地一次性给，一种是拆成碎片分多轮给，然后对比两种方式下的准确率。因为信息总量是完全一样的，唯一的区别就是交付方式不同，所以如果准确率出现了差距，那这个差距就只能归因于“单轮还是多轮”这个变量。

具体操作分为四步。第一步，从现有的高质量测试集里提取一条完整的单轮指令，比如一道数学题或者一个编程任务。第二步，把这条指令拆解成若干个逻辑上独立的信息碎片，每一个碎片单独拿出来信息是不完整的，不足以让 AI 完成整个任务。举个非常直观的例子，有一道题是“面包师一开始烤了 100 个面包，卖掉了 60 个，然后又烤了 45 个，请问现在有多少个面包”。拆成碎片之后就变成了：碎片一说“计算面包数量”，碎片二说“一开始烤了 100 个”，碎片三说“卖掉了 60 个”，碎片四说“又烤了 45 个，现在有多少”。第三步，把这些碎片按照顺序，每一轮只给 AI 看一个，同时要求 AI 在每一轮都基于当前已有的信息做出回答。第四步，把多轮对话后 AI 给出的最终答案，跟一次性输入完整指令的答案进行准确率对比。

这个实验做得非常扎实。总的模拟对话次数超过了 20 万次，这是一个工业级的实验规模。测试了 15 个主流模型，既包括了 GPT-4、Claude、Gemini 这些大家熟知的闭源商业大模型，也包括了 LLaMA 这类开源模型，有大有小，覆盖很全面。任务类型方面，涵盖了代码生成、数学推理、问答、写作、逻辑推理和创意创作六种，基本上把大模型能做的任务类型都包括了进去。信息碎片的数量也有梯度设计，从一个碎片到多个碎片，完整地检验模型在多轮对话中的表现如何随着轮次增加而变化。

实验结果非常令人震惊，论文总结出了三个核心发现。

第一个发现是：所有参与测试的主流模型，在多轮对话场景下的平均准确率全

部大幅下降，降幅达到了 39%。如果单轮对话的准确率在 90%左右，到了多轮场景就迅速掉到了 65%上下。而且这个下降拐点来得非常早，根本不需要几十轮上百轮的复杂对话，仅仅两轮之后，性能衰减就已经很明显了。不管是 GPT-4 这样的大模型，还是相对较小的开源模型，无一幸免，全军覆没。

第二个发现是对性能下降原因的诊断，这也是这篇论文最有洞见的地方。研究者把性能下降拆解成了两个维度来分析：一个是“能力”，也就是模型本身的理解和推理水平有没有降低；另一个是“可靠性”，也就是模型的表现稳不稳定、一不一致。分析结果很有意思：模型的核心理解能力确实有轻微下降，但这个幅度很小，大概只解释了 15%左右的整体性能下降。真正的大头是“可靠性”的崩塌，不可靠性的增幅高达 112%。用大白话翻译就是，多轮对话并没有让模型变笨太多，而是让它变得极其不稳定、极其不可靠，同一个模型处理同一个任务，这次可能做对了，下次可能就做错了，你完全无法预判。对于实际应用来说，这种不可预测性其实比平均准确率下降更可怕，因为你不知道什么时候该信任它的输出。

第三个发现被论文命名为“对话迷失”，这是最值得警惕的一个现象。它的机制是这样的：在第一轮对话中，AI 只拿到了第一个信息碎片，信息不完整，它必须基于有限的信息提前做一个判断，这时候它可能会锁定一个方向。如果这个方向是错的，问题就来了。到了第二轮，用户提供了新的碎片信息，按理说模型应该据此修正之前的理解，但实验结果发现，模型并没有纠正方向，而是继续沿着最初的错误路径往前走。到了第三轮、第四轮，所有信息都补齐了，但 AI 已经彻底回不来了，最终给出的答案仍然是错的。论文对此有一个非常形象的总结：大模型在多轮对话中一旦走错了方向，就会迷路，而且迷路之后就再也回不来了。

最后论文给出了非常实用的建议。对于我们普通用户来说，跟 AI 打交道的时候，最好的策略是尽可能一次性把自己的完整需求写清楚，提供充分的上下文，不要依赖多轮对话去慢慢修正。这样做不但准确率更高，而且节省了反复沟通的时间成本。对于研究者来说，这篇论文揭示了大模型在多轮对话场景下的系统性缺陷，同时也指出现有的 AI 评测体系存在明显漏洞，需要在未来的工作中加以弥补。

这篇论文虽然是计算机领域的基础研究，没有直接讨论金融应用，但它的发现对我们金融行业部署 AI 系统有非常重要的警示意义。

金融行业现在正在大量引入大模型技术。智能客服已经非常普及，客户可以随时在线咨询贷款产品、查询业务进度。大模型还被用来辅助撰写授信报告、分析财务报表、生成合规文档。这些应用很多都涉及多轮对话的场景。比如一个客户想了解贷款产品，他通常不会一上来就说清楚全部需求，而是先问“你们有什么产品”，然后说“我是做餐饮的个体户”，再说“我需要大概 30 万”，再问“利率是多少”。在这个过程中，如果智能客服在某一轮理解偏了，按照论文的发现，它很可能就一直错下去，没法自我纠正。金融行业跟其他行业不一样，给客户推荐了错误的产品、提供了不准确的利率信息，不仅影响客户体验，还可能涉及合规风险和监管处罚。

所以，金融机构在部署大模型驱动的对话系统时，应该充分认识到多轮对话的局限性，在流程设计上做一些针对性的安排。比如在给出最终推荐或者决策之前，强制插入一个需求确认环节，向客户复述一遍“我理解您的需求是……，请问我的理解正确吗”，确认无误之后再进入下一步。再比如，对于涉及信贷审批、风险评估等重大决策的场景，大模型的输出只能作为辅助参考，不能完全替代人工审核。这不是说我们不信任技术，恰恰是因为我们理解了技术的边界在哪里，才能更好地使用它，让它在合适的场景发挥价值，在不合适的场景被有效约束。

二、银行零售信贷客户经理岗位分析与金融科技赋能

接下来我要分享的第二项内容，是银行零售信贷客户经理这个岗位。他们是银行和客户之间最直接的桥梁，一边连接着有小微企业和个人融资需求的客户，一边连接着银行的信贷资金供给，每一笔业务从申请到放款再到回收，都离不开他们的专业服务。

具体来说，零售信贷客户经理的日常工作大致可以分为五个方面。第一是客户开发与维护。他们要主动去挖掘小微企业主、个体工商户和个人的信贷需求，通过走访、电销、渠道合作等方式拓展客户资源，同时跟已有客户保持长期联系，建立信任关系，确保客户有需求的时候第一时间想到他们。第二是贷前尽职调查。这是信贷业务中非常关键的一环，客户经理要实地去客户的经营场所，考察实际的经营状况，同时核验各类申请资料，包括营业执照、财务报表、银行流水、合同单据等等，通过多种信息来源交叉验证客户的真实还款能力。第三是资料整理与上报。按照银行的信贷政策和操作规范，客户经理需要撰写详细的授信报告，把所有调查信息和风险评估结论写清楚，然后把材料录入业务系统，提交给审批部门走流程。第四是贷后管理。贷款放出去之后，客户经理的工作并没有结束，他们要定期跟踪客户的经营动态，监控资金的使用情况和还款记录，确保信贷资产在整个存续期内都是安全的。第五是合规与行政支持。银行是强监管行业，客户经理要严格遵守各项信贷政策和监管要求，同时完成大量的文件归档、报表统计、台账维护等基础行政工作，保障业务运营的合规性。

这个岗位虽然非常重要，但实际工作中面临着很多困难，我把它们归纳为六个比较突出的痛点。

第一个痛点是信息核验低效。客户经理每天要面对大量纸质或电子版的银行流水、合同文件、税务证明、经营执照，需要逐项逐条地人工核对。这个过程不仅耗时，而且人总会疲惫、总会看花眼，疏漏和录入错误难以完全避免。

第二个痛点是事务性工作繁重。撰写授信报告、录入业务系统、整理归档文件——这些事务性的工作占据了客户经理大半的工作时间，真正用来走出去拜访客户、深入了解客户需求、拓展新业务的时间反而被挤占得所剩无几。

第三个痛点是信用评估手段单一。传统的信贷评审过度依赖房产、车辆等有形抵押物和央行征信记录，大量经营状况良好、现金流稳定但缺少合格抵押物的小微企业主和个体户被挡在了银行大门之外。这对银行来说是错失了优质客户资源，对整个社会而言也不利于普惠金融的推进。

第四个痛点是欺诈风险难以防范。现在有些骗贷团伙手法极其专业，伪造的合同、流水、税票足以以假乱真，光靠客户经理肉眼识别和主观经验判断，很难发现问题。一旦中招，坏账就实实在在地产生了。

第五个痛点是贷后管理非常被动。贷后管理主要依靠客户经理定期打电话回访或者上门实地查看，缺乏实时、自动化的监控手段。很多情况下，要等到客户已经出现逾期，银行这边才后知后觉，风险处置的最佳时机早已错过。

第六个痛点是客户服务效率不高。客户想查询贷款审批进度、想了解最新的利率政策，最直接的方式就是打电话找自己的客户经理。客户经理就得放下手头的事情去系统里查询，查到之后再回电话。这个来回折腾的过程效率很低，客户体验也不好，客户经理也被频繁的咨询电话切碎了工作时间。

针对这六个痛点，金融科技提供了一整套精准的解决方案。

针对信息核验低效的问题，OCR 图像识别技术加上大数据平台可以发挥很大作用。客户经理只需要把收到的材料扫描或者拍照上传，系统自动读取和识别关键字段，同时自动连接到工商、税务、征信等外部数据源进行交叉验证，效率提升了 80%

以上，而且机器的识别准确率比人工肉眼要高得多。

针对信用评估单一的问题，基于机器学习的信用评分模型可以整合大量的多维数据，不仅包括传统的征信记录，还包括客户的经营流水、交易行为、上下游关系、甚至社交网络信息等等，构建出一个立体的、动态的信用画像。这样就不再单纯依赖有没有房子、有没有车子来评判一个客户能不能贷款，很多经营状况良好但缺乏抵押物的小微客户就可以获得信贷支持了。

针对欺诈风险难防的问题，知识图谱反欺诈系统是一个非常有力的工具。它把客户、关联人、企业、账户、设备等各种实体之间的关系绘制成一张巨大的网络，通过图算法自动识别异常的资金循环、隐蔽的关联担保、跨平台的骗贷团伙等等，比人工审核敏锐得多，准确率也高得多。

针对事务性工作繁重的问题，生成式 AI 加上 RPA 机器人流程自动化正在改变客户经理的工作方式。生成式 AI 可以根据录入的数据自动撰写授信分析报告，RPA 机器人可以自动把数据录入到各个业务系统里面去。一份原本需要 7 天才能写完的报告，借助大模型技术，3 到 5 分钟就可以生成初稿，效率提升是数量级的。

针对贷后管理被动的问题，智能风险预警平台可以 7 乘 24 小时实时监控贷款客户的资金流向、经营动态、征信变化等各类风险信号，一旦出现异常，系统自动发出预警，客户经理收到提醒后可以提前介入、主动应对，而不是等到客户逾期了再被动处理。

针对客户服务效率低的问题，智能客服加上进度可视化系统可以让客户随时随地在线查询自己的贷款进度，常见的问题由智能客服自动回答，只有真正复杂的问题才需要转人工。这样一来，客户体验大幅改善了，客户经理被频繁咨询电话打扰的次数也大大减少了。

把这几项技术综合起来看，金融科技对银行和客户双方都是实质性的利好。对银行来说，运营成本降下来了，业务处理效率提上去了，风险控制能力增强了，坏账率降低了。对客户来说，申请贷款的流程简化了，审批放款的速度提升了，而且过去那些因为缺少抵押物而被拒之门外的小微客户，现在有机会基于自己的真实信用获得贷款了。这才是普惠金融的真正含义，用技术的手段让金融服务覆盖到更多需要它的人。